ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA KHOA HỌC MÁY TÍNH



MÁY HỌC NÂNG CAO

CS315.G12.LT.TTNT

TRỢ LÝ AI PHÁT HIỆN VÀ ĐỊNH VỊ NỐT PHỔI TRÊN X-QUANG NGỰC

TINH CHỈNH LORA MÔ HÌNH NGÔN NGỮ–THỊ GIÁC CỠ NHỎ

An AI Assistant for Lung Nodule Detection and Localization on Chest X-rays via LoRA-Tuned Small Vision-Language Models

---

BÁO CÁO ĐỒ ÁN CUỐI KỲ

GVHD: ThS. Đặng Việt Dũng

Nhóm 16: Nguyễn Quang Lâm — 25210289
Trần Trọng Tấn — 25210334
Lê Quang Thi — 25210337
Vỏ Cẩm Thu — 25210342

TP. Hồ Chí Minh, tháng 11 năm 2026

Lời cảm ơn

Nhóm xin cảm ơn ThS. Đặng Việt Dũng, giảng viên môn *Máy học nâng cao* (CS315), đã giảng dạy, định hướng đề tài và góp ý cho nhóm trong suốt quá trình thực hiện đồ án cuối kỳ này.

Nhóm cũng cảm ơn các nhóm tác giả đã công bố bộ dữ liệu VinDr-CXR (VinBigData), NIH ChestX-ray14 và JSRT, cùng cộng đồng mã nguồn mở HuggingFace và PyTorch đã cung cấp dữ liệu và hạ tầng để một nhóm sinh viên có thể tinh chỉnh và đánh giá mô hình ngôn ngữ–thị giác.

Đóng góp của thành viên. Bốn thành viên của Nhóm 16 — Nguyễn Quang Lâm (25210289), Trần Trọng Tấn (25210334), Lê Quang Thi (25210337) và Vỏ Cẩm Thu (25210342) — đóng góp ngang nhau vào đồ án.

TP. Hồ Chí Minh, tháng 11 năm 2026

Nhóm thực hiện

Tóm tắt

X-quang ngực (CXR) là xét nghiệm hình ảnh phổ biến nhất, và nhiều ca ung thư phổi lần đầu lộ ra dưới dạng nốt hoặc khối trên CXR, nhưng nốt nhỏ và mờ rất dễ bị bỏ sót. Các mô hình ngôn ngữ–thị giác (VLM) đang được giới thiệu như trợ lý đọc CXR, song các đánh giá độc lập năm 2026 cho thấy sensitivity zero-shot với nốt phổi chỉ đạt 0,6–27,3%; MedGemma-4B đạt sensitivity 5,2% ở specificity 100% — một *chế độ báo bình thường*. Trong khi đó, hệ thống CAD dựa trên CNN đạt AUROC 0,92–0,99. Đồ án xây dựng và đánh giá một **nguyên mẫu trợ lý AI** cho biết ảnh CXR có nốt/khối phổi hay không và chỉ ra vị trí bằng bounding box, dựa trên VLM cỡ nhỏ tinh chỉnh LoRA.

Đồ án gồm ba phần. (i) **Benchmark chuẩn hoá**: prompt và bộ phân tích đầu ra công khai, đầu ra JSON có cấu trúc, ngưỡng chọn trên tập validation và chạy lặp; so sánh MedGemma-4B và Qwen2.5-VL-3B với hai baseline DenseNet-121 và YOLOv8 trên VinBigData (trong phân phối), NIH ChestX-ray14 và JSRT (ngoài phân phối, có phân cấp độ mờ). (ii) **Tinh chỉnh LoRA** MedGemma-4B cho bài toán chỉ phân loại và phân loại kèm định vị, có và không có cân bằng lớp, nhằm kéo mô hình ra khỏi chế độ báo bình thường. (iii) **Kiểm tra trợ lý có nhìn đúng chỗ không**: IoU định vị, so sánh che nốt với che vùng ngẫu nhiên cùng diện tích, và phân tầng theo kích thước và độ mờ của nốt. Chỉ số chính là sensitivity ở specificity 0,90, với mục tiêu 0,60; các chỉ số phụ gồm AUC-ROC, AUC-PR, calibration và FROC, kèm khoảng tin cậy 95% bằng bootstrap.

Kết quả. [Điền sau thí nghiệm E1–E5.]

Kết luận. [Điền sau thí nghiệm E1–E5.] Đây là nguyên mẫu nghiên cứu, không dùng cho quyết định lâm sàng.

Từ khoá: trợ lý AI, mô hình ngôn ngữ–thị giác, LoRA, nốt phổi, X-quang ngực, phát hiện và định vị tổn thương, mất cân bằng lớp.

Mục lục

Lời cảm ơn **i**

Tóm tắt **ii**

Danh sách hình vẽ **vi**

Danh sách bảng **vi**

Danh mục từ viết tắt **vii**

1 Giới thiệu **1**
1.1 Bối cảnh . . . 1
1.2 Vấn đề . . . 1
1.3 Mục tiêu . . . 2
1.4 Đóng góp . . . 2
1.5 Cấu trúc báo cáo . . . 3

2 Cơ sở lý thuyết và tổng quan tài liệu **4**
2.1 Nốt phổi trên X-quang ngực và hệ thống CAD . . . 4
2.2 Mô hình ngôn ngữ–thị giác . . . 4
2.3 Thích ứng hạng thấp (LoRA) . . . 4
2.4 Mất cân bằng lớp và học lối tắt . . . 5
2.5 Đánh giá chẩn đoán . . . 6
2.6 Tổng quan tài liệu và khoảng trống . . . 6

3 Phương pháp **8**
3.1 Kiến trúc hệ thống . . . 8
3.2 Luồng xử lý của trợ lý . . . 8
3.3 Mô hình . . . 9
3.4 Các cấu hình . . . 10
3.5 Định dạng huấn luyện và suy luận . . . 10
3.6 Huấn luyện . . . 11
3.7 Kiểm toán "nhìn đúng chỗ" . . . 12

4 Dữ liệu **14**
4.1 Các bộ dữ liệu . . . 14
4.2 Gán nhãn và hợp nhất box . . . 14

4.3 Chia dữ liệu 14
4.4 Tiền xử lý 15
4.5 Thống kê mô tả 15

5 Thí nghiệm, đánh giá và kết quả 17
5.1 Thiết kế thí nghiệm 17
5.2 Chỉ số đánh giá 18
5.3 Kết quả chính 19
5.4 Định vị 20
5.5 Chế độ báo bình thường và tác dụng của cân bằng lớp 20
5.6 Kiểm toán "nhìn đúng chỗ" 20

6 Kết luận, hạn chế và hướng phát triển 21
6.1 Kết luận 21
6.2 Hạn chế 21
6.3 An toàn và đạo đức 21
6.4 Hướng phát triển 22

Tài liệu tham khảo 23

Phụ lục 25
A Quy trình thực nghiệm bắt buộc 25
B Prompt và định dạng đầu ra 27
C Siêu tham số 28
D Mã nguồn và tái lập 28
E Mức kiểm chứng tài liệu 28

Danh sách hình vẽ

1 LoRA trong đồ án. Trái: trọng số gốc W_0 đông cứng; cập nhật hạng thấp $\Delta W = \frac{\alpha}{r} BA$ với $r = 16$, $\alpha = 32$, dropout 0,05; B khởi tạo bằng 0 nên mô hình ban đầu trùng mô hình gốc. Phải: LoRA chỉ gắn vào attention và MLP của LLM; bộ mã hoá ảnh và lớp chiếu đông cứng. 5

2 Minh hoạ khái niệm, dùng đường cong tổng hợp (mô hình hai phân phối chuẩn), **không phải kết quả** của đồ án. Trái: sensitivity và specificity theo ngưỡng; t_{90} là ngưỡng cho specificity 0,90. Phải: đường ROC; vùng xanh là vùng đạt tiêu chí (specificity $\geq$ 0,90, sensitivity $\geq$ 0,60); chấm đen là một mô hình ở chế độ báo bình thường. 6

3 Kiến trúc hệ thống theo tầng. Cột trái ghi module và script tương ứng trong `code/`. Ô xám: VLM dùng nguyên trạng; ô xanh dương: VLM có LoRA; ô xanh lá: baseline CNN; ô cam: các file chỉ tính trên validation, dùng để chọn ngưỡng và cấu hình (C4 và cấu hình cho E5 được chọn từ `val_selection.csv`); ô đỏ: kiểm toán E5. 8

4 Luồng xử lý của trợ lý cho một ảnh. Chỉ các ma trận LoRA trong LLM (ô xanh) được huấn luyện; bộ mã hoá ảnh (ô xám) đông cứng. Nhánh trên cho câu trả lời đọc được và box; nhánh dưới cho điểm liên tục dùng để chọn ngưỡng trên validation. 9

5 Cách tính điểm liên tục $s(x)$ cho VLM và chọn ngưỡng. Trái: hai câu trả lời ép buộc dùng chung ảnh, câu hỏi và tiền tố; hiệu log-xác suất qua hàm sigmoid cho $s(x)$. Phải (minh hoạ, không phải kết quả): t_{90} đặt sao cho 90% ảnh âm của validation có điểm dưới ngưỡng; ảnh dương có điểm trên ngưỡng được tính là phát hiện. 11

6 Định dạng một mẫu huấn luyện và mặt nạ loss (minh hoạ; số token ảnh và mẫu chat phụ thuộc mô hình). Ô xám: token ảnh, câu hỏi và tiền tố vai trò, bị loại khỏi loss. Ô màu: token đáp án được tính loss; ở C3, mọi token đáp án của ca dương nhân với w_+. Loss chia cho tổng số token nhãn của cả cửa sổ tích luỹ gradient. 12

7 Minh hoạ ba phép thử của kiểm toán "nhìn đúng chỗ" (ảnh giản lược). Khung xanh: box nốt tham chiếu; khung đỏ nét đứt: vùng T1 (box nới 10%); khung cam nét đứt: vùng T2 cùng kích thước, $\geq$ 90% nằm trong mặt nạ phổi. Δ_{occ} là hiệu tỷ lệ đổi đáp án giữa T1 và T2, tính bắt cặp trên cùng tập ảnh. 13

8 Chia dữ liệu và định nghĩa nhãn. VinBigData chia 70/10/20 theo ảnh; validation chỉ dùng để chọn ngưỡng và cấu hình; ba tập test (một trong phân phối, hai ngoài phân phối) chỉ được đánh giá một lần. Số ca dương là ước tính từ [32]; số thật lấy từ `e0_data.md` sau E0. 15

9 Thứ tự chạy thí nghiệm. E1–E3 độc lập với nhau sau E0. `make_report.py` lần 1 sinh `val_selection.csv` và `thresholds.json`; cổng chọn (khung cam) chỉ dùng số trên validation để chọn cấu hình LoRA tốt nhất cho E4 và E5. Lần chạy cuối của `make_report.py` gộp mọi file dự đoán thành bảng báo cáo. 18

10 Luồng đánh giá và thống kê trong `make_report.py`. Ngưỡng chỉ chọn trên validation rồi áp nguyên lên test; chỉ số định vị dùng box có điểm $\geq t_{90}$; khoảng tin cậy bằng bootstrap theo ảnh; so sánh bắt cặp bằng McNemar và DeLong, hiệu chỉnh Holm. 19

11 Lịch **đề xuất** cho phần việc còn lại, từ 14/11 đến 18/12/2026; chưa phải lịch đã chốt. Màu theo loại việc như các hình trước: xanh lá baseline, xám zero-shot, xanh dương LoRA, cam bước chọn và tổng hợp, đỏ kiểm toán. 27

Danh sách bảng

1 Những gì đã có và khoảng trống đồ án nhắm tới. 7

2 Các cấu hình được so sánh. 10

3 Các phép thử phụ thuộc thị giác. 13

4 Vai trò của từng bộ dữ liệu. 14

5 Thống kê dữ liệu sau tiền xử lý (điền sau E0). 16

6 Các thí nghiệm. 17

7 Sensitivity ở specificity 0,90 và AUC-ROC trên ba tập test 19

8 Chỉ số định vị 20

9 Tỷ lệ đổi đáp án dưới các phép thử che vùng 20

10 Đầu vào, lệnh, đầu ra của từng bước và chỗ trong báo cáo mà bước đó điền. Đường dẫn tương đối với thư mục gốc dự án; `M = data/processed`, `O = outputs`. 26

11 Siêu tham số huấn luyện. 28

Danh mục từ viết tắt

Viết tắt	Ý nghĩa
AI	Artificial Intelligence — trí tuệ nhân tạo
AUC	Area Under the Curve — diện tích dưới đường cong (ROC hoặc PR)
CAD	Computer-Aided Detection — hệ thống phát hiện có máy tính hỗ trợ
CI	Confidence Interval — khoảng tin cậy
CNN	Convolutional Neural Network — mạng nơ-ron tích chập
CXR	Chest X-ray — X-quang ngực
ECE	Expected Calibration Error — sai số hiệu chỉnh kỳ vọng
ERM	Empirical Risk Minimization — cực tiểu rủi ro thực nghiệm
FROC	Free-response ROC — đường ROC đáp ứng tự do
IoU	Intersection over Union — tỷ lệ giao trên hợp
LLM	Large Language Model — mô hình ngôn ngữ lớn
LoRA	Low-Rank Adaptation — thích ứng hạng thấp
MLLM	Multimodal LLM — mô hình ngôn ngữ lớn đa phương thức
PPV / NPV	Positive / Negative Predictive Value — giá trị dự đoán dương / âm
ROC	Receiver Operating Characteristic
SFT	Supervised Fine-Tuning — tinh chỉnh có giám sát
ViT	Vision Transformer
VLM	Vision-Language Model — mô hình ngôn ngữ–thị giác
WBF	Weighted Boxes Fusion — hợp nhất box có trọng số

1 Giới thiệu

1.1 Bối cảnh

Ung thư phổi là nguyên nhân tử vong do ung thư hàng đầu thế giới [1]. X-quang ngực (CXR) là xét nghiệm hình ảnh được chỉ định nhiều nhất, và nhiều ca ung thư phổi lần đầu lộ ra dưới dạng *nốt* (đường kính $\leq 3\,\text{cm}$) hoặc *khối* ($> 3\,\text{cm}$) trên CXR. Nốt nhỏ, mờ hoặc bị xương sườn, tim che khuất rất dễ bị bỏ sót: trên các tập làm giàu ca bệnh, sensitivity của người đọc chỉ khoảng 57–65% [21, 22], và với các ca ung thư từng bị bỏ sót trước đó chỉ còn 40–53% [14].

Các hệ thống CAD dựa trên CNN đã đạt AUROC 0,92–0,99 trên các tập ngoài [9], và một thử nghiệm ngẫu nhiên có đối chứng cho thấy CAD làm tăng tỷ lệ phát hiện nốt cần xử trí từ 0,25% lên 0,59% [10]. Song song, các mô hình ngôn ngữ–thị giác (VLM) và LLM đa phương thức đang được giới thiệu như *trợ lý đọc CXR*: chúng nhận ảnh, trả lời bằng ngôn ngữ tự nhiên và có thể giải thích. Câu hỏi thực tế đặt ra là: các trợ lý này có thật sự *thấy* nốt phổi hay không?

1.2 Vấn đề

Các đánh giá độc lập năm 2026 cho câu trả lời đáng lo ngại:

- Sáu VLM zero-shot trên 247 ảnh JSRT chỉ đạt sensitivity 0,6–27,3%. MedGemma-4b-it đạt 5,2% (8/154) ở specificity 100%; với nốt mờ nhất (độ mờ 1), mọi mô hình đều $\leq 12\%$ [3].
- Chín hệ thống trên MosMedData VII (83 ảnh): AUC tốt nhất 0,743 (BiomedCLIP); LLM đa năng tốt nhất (Claude 3.7 Sonnet) đạt AUC 0,625; CXR-LLaVA chỉ đạt sensitivity 0,079 [2]. Trên cùng nguồn dữ liệu, CAD CNN thương mại đạt AUC 0,956 [12].
- Bốn MLLM đa năng chỉ phát hiện khoảng 10% ca ác tính đơn ổ [4]; thêm ngữ cảnh lâm sàng có cấu trúc giúp accuracy chung tăng, nhưng ung thư phổi vẫn chỉ đúng 20% [5].

Kiểu sai phổ biến ở các VLM chuyên CXR là **chế độ báo bình thường** (*normal-default mode*): specificity gần 1, sensitivity gần 0. Có hai giả thuyết bổ trợ nhau. Về thị giác, bộ mã hoá ViT làm mất tín hiệu tổn thương nhỏ ở bước gộp toàn cục; probe tuyến tính trên patch cục bộ lấy lại được tín hiệu, nâng AUC nốt của MedSigLIP từ 0,805 lên 0,955 [25]. Về dữ liệu, báo cáo huấn luyện phần lớn là bình thường, nên mô hình nghiêng về câu trả lời "không có bất thường" — một dạng *học lối tắt* khi lớp dương hiếm.

Đã có tiền lệ tinh chỉnh VLM/LLM trên CXR, nhưng cho tác vụ khác: QLoRA một VLM nhỏ để sinh báo cáo [29], LoRA cho sinh báo cáo [30], và tinh chỉnh Qwen2.5-VL cho grounding cụm từ tổng quát [31]. Trong phạm vi 90 bài nhóm đã khảo sát, **chưa có nghiên cứu nào tinh chỉnh VLM cỡ nhỏ để phát hiện và định vị nốt/khối phổi trên CXR rồi so trực tiếp với CNN trên cùng cách chia dữ liệu**, và cũng

chưa có nghiên cứu nào kiểm tra mô hình sau tinh chỉnh có nhìn đúng vị trí nốt hay không.

1.3 Mục tiêu

Đồ án xây dựng và đánh giá một **nguyên mẫu trợ lý AI** nhận một ảnh CXR, cho biết có nốt/khối phổi hay không và chỉ ra vị trí bằng bounding box. Trợ lý dựa trên VLM cỡ nhỏ (3–4 tỷ tham số) tinh chỉnh bằng LoRA, đủ nhẹ để huấn luyện trên một GPU Colab. Cụ thể:

1. **Kiểm toán zero-shot có chuẩn hoá:** đánh giá MedGemma-4B và Qwen2.5-VL-3B với prompt chung, đầu ra có cấu trúc, ngưỡng chọn trên validation và chạy lặp, đặt cạnh baseline CNN trên cùng split.
2. **Tinh chỉnh LoRA** cho hai bài toán: (a) có hay không có nốt/khối; (b) có nốt/khối kèm box.
3. **Chống chế độ báo bình thường:** so sánh LoRA chuẩn với LoRA cân bằng lớp.
4. **Kiểm tra trợ lý có nhìn đúng chỗ không:** định vị (IoU, hit rate), phép thử che nốt so với che vùng ngẫu nhiên cùng diện tích, phân tầng theo kích thước và độ mờ của nốt.

> **Câu hỏi nghiên cứu chính.** (Q1) LoRA có đưa sensitivity của VLM, ở specificity 0,90, lên tối thiểu 0,60 trên tập test trong phân phối không? (Q2) Cải thiện đó có còn khi kiểm tra ngoài phân phối (JSRT) và khi che nốt không?

Ngưỡng 0,60 nằm cùng khoảng với sensitivity của người đọc trên các tập làm giàu ca bệnh nêu trên, nhưng không mốc nào đo ở cùng điểm vận hành specificity 0,90. Vì vậy báo cáo *không* so sánh "ngang bác sĩ"; ngưỡng này cũng thấp hơn rõ so với CAD chuyên biệt [17, 15].

1.4 Đóng góp

1. **Benchmark nốt CXR chuẩn hoá cho VLM**, với prompt và parser công khai, chọn ngưỡng trên validation và ba tập test (trong phân phối, ngoài phân phối, có phân cấp độ mờ) — bản tái lập có kiểm soát và quy mô lớn hơn của [2, 3].
2. **Nguyên mẫu trợ lý dựa trên VLM cỡ nhỏ tinh chỉnh LoRA cho phát hiện và định vị nốt/khối phổi**, so trực tiếp với CNN classifier và detector trên cùng split; theo hiểu biết của nhóm, đây là bằng chứng đầu tiên cho tác vụ này trong phạm vi tài liệu đã khảo sát.
3. **Phân tích chế độ báo bình thường và tác dụng của cân bằng lớp** khi tinh chỉnh VLM cho tổn thương hiếm và nhỏ — phần gắn trực tiếp với nội dung học có mất cân bằng lớp của môn học.
4. **Kiểm toán "đúng vì đúng lý do"**: kết hợp IoU với phép che nốt so với che

vùng ngẫu nhiên, phân tầng theo kích thước và độ mờ.

> **Phạm vi.** "Trợ lý" trong đồ án là *nguyên mẫu nghiên cứu*. Kết quả không dùng cho quyết định lâm sàng và không được trình bày như một công cụ sẵn sàng triển khai (xem Mục 6).

1.5 Cấu trúc báo cáo

Mục 2 trình bày cơ sở lý thuyết và tổng quan tài liệu. Mục 3 mô tả kiến trúc trợ lý, các cấu hình và quy trình huấn luyện. Mục 4 mô tả dữ liệu. Mục 5 trình bày thiết kế thí nghiệm, cách đánh giá và kết quả. Mục 6 kết luận, nêu hạn chế và hướng phát triển.

2 Cơ sở lý thuyết và tổng quan tài liệu

2.1 Nốt phổi trên X-quang ngực và hệ thống CAD

Nốt phổi là tổn thương mờ, tròn, đường kính tới 3 cm; tổn thương lớn hơn gọi là khối. Trên CXR, nốt là tín hiệu nhỏ so với cả ảnh: một nốt 10 mm chỉ chiếm vài chục pixel trên ảnh đã thu về 896×896. CAD cho nốt trên CXR thường là CNN phân loại hoặc phát hiện đối tượng, huấn luyện trên box do bác sĩ vẽ. Các hệ thống này đạt AUROC 0,86–0,99 trên tập ngoài [9, 17, 15] và đã có bằng chứng lâm sàng từ RCT [10]. Độ phân giải đầu vào ảnh hưởng rõ tới hiệu năng phát hiện tổn thương nhỏ [18]; với CAD nốt/khối, kích thước ma trận khoảng 896 là tối ưu [19].

2.2 Mô hình ngôn ngữ–thị giác

Một VLM sinh văn bản gồm ba khối: (i) bộ mã hoá ảnh, thường là ViT [39], biến ảnh thành chuỗi token thị giác; (ii) lớp chiếu đưa token thị giác vào không gian nhúng của LLM; (iii) LLM tự hồi quy sinh câu trả lời theo prompt. Với ảnh x, câu hỏi q và câu trả lời $y = (y_1, \dots, y_T)$, mô hình học

$$p_\theta(y \mid x, q) = \prod_{t=1}^{T} p_\theta\big(y_t \mid y_{<t},\, E(x),\, q\big), \tag{1}$$

trong đó $E(x)$ là chuỗi token thị giác.

Đồ án dùng hai VLM mở cỡ nhỏ:

- **MedGemma-4B-it** [6]: mô hình y khoa dựa trên Gemma 3, bộ mã hoá MedSigLIP, nhận ảnh 896×896. Zero-shot, nó là ví dụ điển hình của chế độ báo bình thường (sensitivity 5,2%, specificity 100% [3]).
- **Qwen2.5-VL-3B-Instruct** [41]: mô hình đa năng, độ phân giải động, có sẵn khả năng xuất toạ độ box; đã được chứng minh học được grounding trên CXR sau tinh chỉnh [31].

2.3 Thích ứng hạng thấp (LoRA)

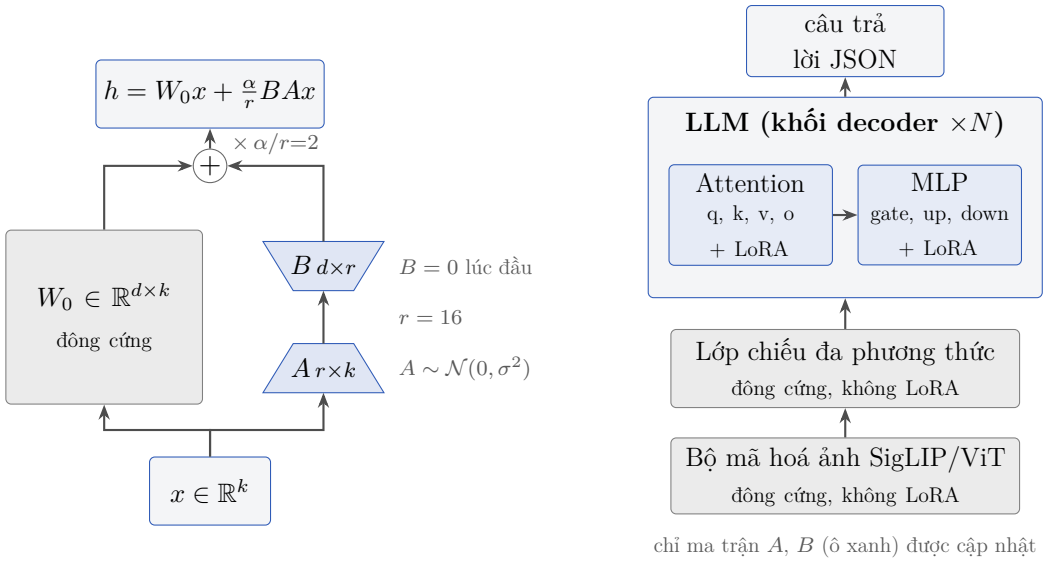
Tinh chỉnh toàn bộ một VLM 4 tỷ tham số vượt quá ngân sách một GPU. LoRA [40] giữ nguyên trọng số gốc $W_0 \in \mathbb{R}^{d\times k}$ và học một cập nhật hạng thấp:

$$W = W_0 + \Delta W = W_0 + \frac{\alpha}{r} BA, \qquad B \in \mathbb{R}^{d\times r},\ A \in \mathbb{R}^{r\times k},\ r \ll \min(d,k). \tag{2}$$

A khởi tạo ngẫu nhiên, B khởi tạo bằng 0 nên mô hình ban đầu trùng mô hình gốc. Với $r = 16$, số tham số cần học chỉ chiếm một phần rất nhỏ so với tham số mô hình.

Đồ án gắn LoRA vào các lớp attention và MLP của LLM và *đông cứng bộ mã hoá ảnh*. Đây là một câu hỏi lý thuyết đáng quan tâm: nếu tín hiệu nốt đã bị mất ở bước

gộp của bộ mã hoá [25], thì một cập nhật hạng thấp phía LLM có đủ để đưa tín hiệu cục bộ còn lại vào đầu ra ngôn ngữ hay không? Hình 1 tóm tắt cơ chế LoRA và vị trí gắn LoRA trong VLM. Với $\alpha = 32$ và $r = 16$, hệ số tỷ lệ $\alpha/r = 2$. LoRA chỉ gắn vào các phép chiếu `q/k/v/o_proj` (attention) và `gate/up/down_proj` (MLP) của LLM; mọi module của bộ mã hoá ảnh và lớp chiếu đa phương thức bị loại khỏi danh sách đích.



Hình 1. LoRA trong đồ án. Trái: trọng số gốc W_0 đông cứng; cập nhật hạng thấp $\Delta W = \frac{\alpha}{r}BA$ với $r = 16$, $\alpha = 32$, dropout 0,05; B khởi tạo bằng 0 nên mô hình ban đầu trùng mô hình gốc. Phải: LoRA chỉ gắn vào attention và MLP của LLM; bộ mã hoá ảnh và lớp chiếu đông cứng.

2.4 Mất cân bằng lớp và học lối tắt

Gọi $\pi = P(Y{=}1)$ là tỷ lệ ca dương. Trong VinBigData, $\pi \approx 2{,}7\%$ [32]. Với ERM dùng loss 0–1, bộ phân loại hằng "luôn trả lời không" có rủi ro π, tức accuracy $1 - \pi \approx 97\%$ — một nghiệm cục bộ rất hấp dẫn. Khi huấn luyện VLM bằng cross-entropy trên token, hiện tượng tương tự xuất hiện ở token trả lời "yes"/"no"; một nghiên cứu ghi nhận tinh chỉnh trên ChestX-ray14 làm sensitivity giảm dưới 15% [28].

Hai biện pháp kinh điển của học có chi phí (cost-sensitive learning) được dùng trong đồ án:

- **Lấy mẫu lại:** oversampling ca dương tới tỷ lệ 1:1 trong mỗi epoch, tương đương thay phân phối huấn luyện để $\pi' = 0{,}5$.
- **Trọng số loss:** nhân loss của token trả lời với trọng số w_+ cho ca dương:

$$\mathcal{L} = -\sum_i w(y_i) \sum_{t \in \mathcal{A}_i} \log p_\theta\big(y_{i,t} \mid y_{i,<t}, x_i, q\big), \tag{3}$$

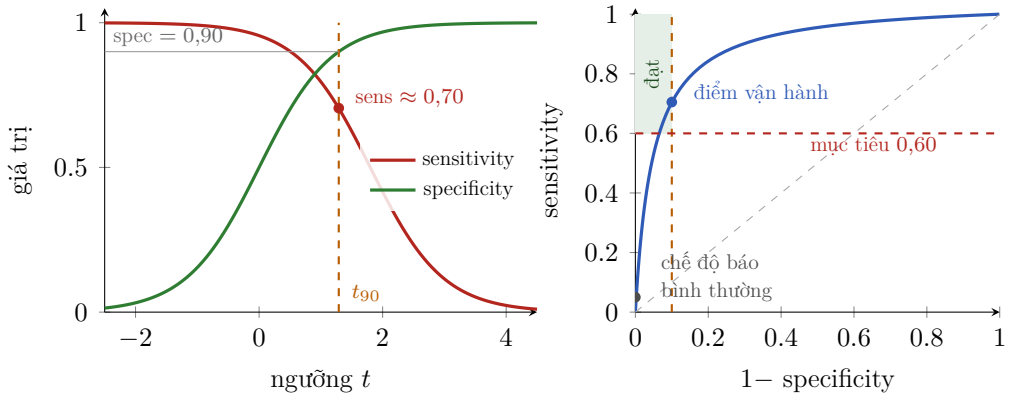
  trong đó $\mathcal{A}_i$ là tập vị trí token thuộc câu trả lời.

Lấy mẫu lại làm lệch xác suất đầu ra so với tỷ lệ thật, nên ngưỡng quyết định phải chọn lại trên validation và cần đánh giá calibration [20].

2.5 Đánh giá chẩn đoán

- **Mức ảnh:** sensitivity, specificity, PPV, NPV, đường ROC và AUC. Khi lớp dương hiếm, AUC-ROC có thể lạc quan; AUC-PR và calibration (ECE, Brier) bổ sung thông tin [20]. PPV phụ thuộc tỷ lệ bệnh: $\mathrm{PPV} = \frac{\mathrm{Se}\,\pi}{\mathrm{Se}\,\pi + (1-\mathrm{Sp})(1-\pi)}$.
- **Điểm vận hành:** sensitivity ở specificity cố định (0,90 và 0,95), ngưỡng chọn trên validation.
- **Định vị:** IoU giữa box dự đoán và box chuẩn; FROC biểu diễn sensitivity mức tổn thương theo số dương tính giả trên mỗi ảnh.
- **So sánh bắt cặp:** McNemar cho sensitivity/specificity, DeLong [46] cho AUC, hiệu chỉnh Holm khi so nhiều cặp; khoảng tin cậy 95% bằng bootstrap theo ảnh.

Hình 2 giải thích vì sao đồ án chọn chỉ số chính là sensitivity ở specificity 0,90 thay vì accuracy hay sensitivity ở một ngưỡng mặc định. Khi tăng ngưỡng t, specificity tăng còn sensitivity giảm. Một mô hình ở chế độ báo bình thường nằm ở góc dưới trái của ROC: specificity gần 1 nhưng gần như không phát hiện được ca dương. Cố định specificity 0,90 cho phép so mọi mô hình, VLM hay CNN, ở cùng một mức báo động giả. Tiêu chí thành công của đồ án là sensitivity $\geq 0{,}60$ tại điểm này trên VinBigData test.



Hình 2. Minh hoạ khái niệm, dùng đường cong tổng hợp (mô hình hai phân phối chuẩn), **không phải kết quả** của đồ án. Trái: sensitivity và specificity theo ngưỡng; t_{90} là ngưỡng cho specificity 0,90. Phải: đường ROC; vùng xanh là vùng đạt tiêu chí (specificity $\geq 0{,}90$, sensitivity $\geq 0{,}60$); chấm đen là một mô hình ở chế độ báo bình thường.

2.6 Tổng quan tài liệu và khoảng trống

Nhóm khảo sát 90 bài từ arXiv, PubMed, Semantic Scholar, OpenAlex, Europe PMC, Consensus, Undermind và Scopus (giới hạn ở tạp chí uy tín). Mức đọc: 34 bài toàn văn, 53 bài tóm tắt, 3 bài chỉ tiêu đề. Bảng 1 tóm tắt khoảng trống.

Bảng 1. Những gì đã có và khoảng trống đồ án nhắm tới.

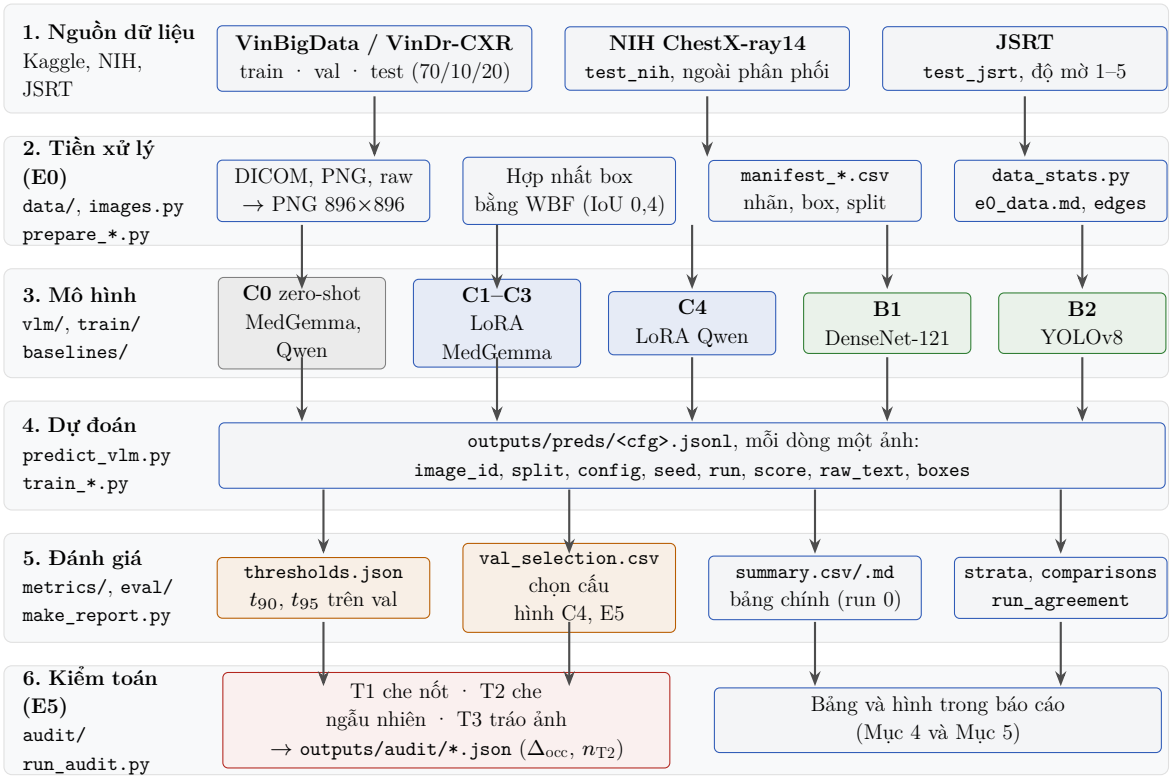
Việc	**Đã có**	**Còn trống**
Đánh giá VLM zero-shot cho nốt CXR	83–247 ảnh, một nguồn, prompt khác nhau; [2] chọn ngưỡng trên tập test, [3] chỉ có đầu ra nhị phân	Đánh giá chuẩn hoá, nhiều tập, có CNN trên cùng split
Tinh chỉnh VLM/LLM trên CXR	Cho sinh báo cáo [29, 30] hoặc grounding tổng quát [31]	LoRA VLM nhỏ cho phát hiện và định vị nốt/khối, so với CNN
Định vị nốt bằng VLM	Gộp thành "lung lesion" [26]; không có nốt/khối [27]	Định vị riêng nốt/khối, sau tinh chỉnh
Phân tầng kích thước, độ mờ	Theo độ mờ JSRT nhưng chỉ zero-shot [3]; CAD [13, 19]	Phân tầng có hệ thống, trước và sau tinh chỉnh
Cơ chế bỏ sót nốt nhỏ	Probe trên embedding đông cứng [25]	Kiểm chứng trên VLM sinh văn bản sau tinh chỉnh
Đánh giá theo tỷ lệ bệnh	Nghiên cứu VLM chỉ báo accuracy, sens/spec	AUC-PR, calibration, PPV ở tỷ lệ bệnh thực tế

Các khoảng trống trên đúng trong phạm vi 90 bài đã khảo sát; đó không phải bằng chứng tuyệt đối rằng chưa ai làm.

3 Phương pháp

3.1 Kiến trúc hệ thống

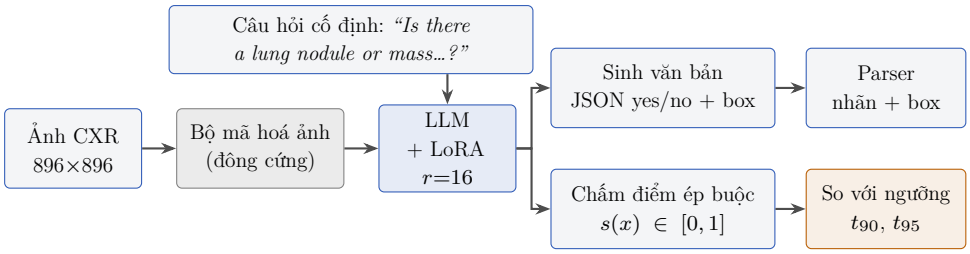
Hình 3 là kiến trúc tổng thể của hệ thống, chia thành sáu tầng. Mỗi tầng ứng với một nhóm module trong gói `nodulecxr` và một nhóm script trong `code/scripts/`. Dữ liệu đi một chiều từ trên xuống. Ảnh gốc của ba nguồn được chuẩn hoá thành PNG 896×896 và một file `manifest_*.csv` cho mỗi nguồn. Mọi mô hình, VLM hay CNN, đều ghi dự đoán theo cùng một định dạng JSONL. Một chương trình đánh giá duy nhất (`make_report.py`) đọc các file này, chọn ngưỡng trên validation và sinh mọi bảng của báo cáo. Kiểm toán E5 dùng ngưỡng và cấu hình do tầng đánh giá chọn. Nhờ vậy, VLM và CNN được so trên cùng split, cùng ngưỡng và cùng mã tính chỉ số.



Hình 3. Kiến trúc hệ thống theo tầng. Cột trái ghi module và script tương ứng trong `code/`. Ô xám: VLM dùng nguyên trạng; ô xanh dương: VLM có LoRA; ô xanh lá: baseline CNN; ô cam: các file chỉ tính trên validation, dùng để chọn ngưỡng và cấu hình (C4 và cấu hình cho E5 được chọn từ `val_selection.csv`); ô đỏ: kiểm toán E5.

3.2 Luồng xử lý của trợ lý

Hình 4 mô tả luồng xử lý của trợ lý cho một ảnh. Ảnh CXR được chuẩn hoá về 896×896 và đưa vào VLM cùng một câu hỏi cố định. VLM trả lời bằng JSON gồm kết luận có/không và danh sách box. Song song với việc sinh văn bản, mô hình được chấm điểm trên hai câu trả lời ép buộc để có điểm liên tục $s(x)$ (Mục 3.5). Parser kiểm tra cú pháp và chuyển câu trả lời thành nhãn và box; điểm $s(x)$ dùng để vẽ ROC và chọn ngưỡng.



Hình 4. Luồng xử lý của trợ lý cho một ảnh. Chỉ các ma trận LoRA trong LLM (ô xanh) được huấn luyện; bộ mã hoá ảnh (ô xám) đông cứng. Nhánh trên cho câu trả lời đọc được và box; nhánh dưới cho điểm liên tục dùng để chọn ngưỡng trên validation.

3.3 Mô hình

VLM chính: MedGemma-4B-it. LoRA $r = 16$, $\alpha = 32$, dropout 0,05, gắn vào các lớp attention và MLP của LLM; bộ mã hoá ảnh đông cứng. Lý do chọn: (i) là mô hình y khoa mở mới nhất [6]; (ii) zero-shot nó rơi đúng vào chế độ báo bình thường [3], nên câu hỏi "LoRA có kéo mô hình ra khỏi chế độ đó không" có tính thông tin cao; (iii) đầu vào 896×896 trùng với độ phân giải tối ưu cho CAD nốt [19], nên nút thắt nhiều khả năng nằm ở cách gộp đặc trưng và dữ liệu, không ở độ phân giải. Rủi ro: MedGemma không được huấn luyện mạnh để xuất toạ độ, nên khả năng định vị phải học hoàn toàn qua LoRA.

VLM thứ hai: Qwen2.5-VL-3B-Instruct. Dùng cho zero-shot và cho cấu hình LoRA tốt nhất, để so mô hình y khoa với mô hình đa năng có sẵn khả năng xuất box. Lưu ý: [3] thử Qwen3-VL-8B (sensitivity 7,8%), không phải Qwen2.5-VL-3B, nên không so trực tiếp số liệu.

Baseline CNN.

- **B1 — classifier:** DenseNet-121 [42] tiền huấn luyện trên CXR (thư viện TorchXRayVision [43]), fine-tune nhị phân nốt/khối.
- **B2 — detector:** YOLOv8 [44] huấn luyện trên box nốt/khối, đầu vào 896.

3.4 Các cấu hình

Bảng 2. Các cấu hình được so sánh.

Mã	Cấu hình	Đầu ra
C0	VLM zero-shot (MedGemma-4B, Qwen2.5-VL-3B)	JSON yes/no + box
C1	LoRA MedGemma-4B, chỉ phân loại	yes/no
C2	LoRA MedGemma-4B, phân loại và định vị	yes/no + box
C3	C2 + cân bằng lớp (oversampling ca dương 1:1, trọng số loss cho token trả lời)	yes/no + box
C4	Cấu hình tốt nhất trong C1–C3, áp lên Qwen2.5-VL-3B	như cấu hình được chọn
B1	DenseNet-121 classifier	xác suất
B2	YOLOv8 detector	box + điểm

Mở rộng, không thuộc cam kết. C5 — VLM có hỗ trợ vùng: đưa box đề xuất của B2, hoặc ảnh cắt theo box, vào prompt để VLM xác nhận và mô tả, nhắm vào giả thuyết gộp toàn cục [25]. C6 — chia ô hoặc cắt theo trường phổi để vượt 896 px hiệu dụng [18, 19].

3.5 Định dạng huấn luyện và suy luận

Câu hỏi cố định.

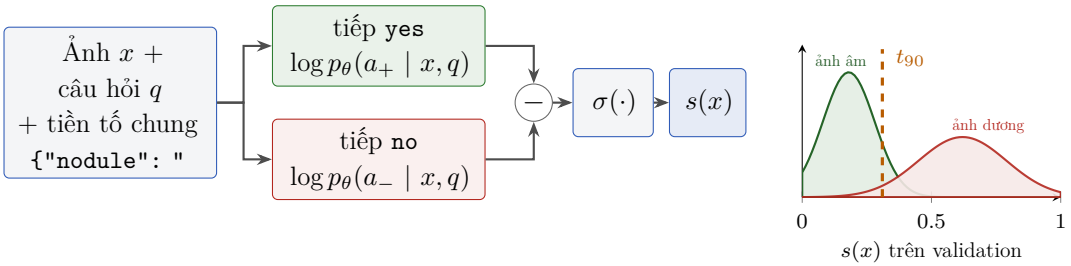
- Định vị (C0, C2–C4): *"Is there a lung nodule or mass on this chest X-ray? If yes, give the bounding box(es) in pixel coordinates. Answer in JSON."*
- Chỉ phân loại (C1): *"Is there a lung nodule or mass on this chest X-ray? Answer in JSON."*

Đáp án đích. Sinh tự động từ nhãn gốc: box của các bác sĩ được hợp nhất bằng WBF [45], quy về toạ độ pixel trên ảnh 896×896 dạng $[x_1, y_1, x_2, y_2]$. Ví dụ ca dương có đáp án `{"nodule": "yes", "boxes": [[412, 230, 468, 281]]}`, còn ca âm có đáp án `{"nodule": "no", "boxes": []}`. Với C1 (chỉ phân loại), đáp án chỉ có khoá `nodule`. Không dùng câu hỏi–đáp do LLM sinh, để tránh nhiễu nhãn. Không đưa ngữ cảnh lâm sàng vào prompt trong điều kiện chính, vì ngữ cảnh có thể "lộ" đáp án [5].

Điểm liên tục. Để vẽ ROC và chọn ngưỡng, VLM cần một điểm liên tục chứ không chỉ nhãn. Đồ án so log-xác suất của hai chuỗi trả lời ép buộc $a_+ =$ `{"nodule": "yes` và $a_- =$ `{"nodule": "no` (không có dấu nháy đóng), tính từ token đầu tiên mà hai chuỗi khác nhau:

$$s(x) = \frac{p_\theta(a_+ \mid x, q)}{p_\theta(a_+ \mid x, q) + p_\theta(a_- \mid x, q)} = \sigma\big(\log p_\theta(a_+ \mid x, q) - \log p_\theta(a_- \mid x, q)\big). \quad (4)$$

Hình 5 minh hoạ cách tính. Ngưỡng t_{90} là ngưỡng nhỏ nhất mà specificity trên validation đạt $\geq 0{,}90$, tức khoảng 90% ảnh âm của validation có điểm dưới ngưỡng; t_{95} tính tương tự. Ngưỡng được tính riêng cho từng bộ (cấu hình, seed, lần chạy), lưu trong `thresholds.json` với khoá `config|seed|run`, rồi áp nguyên lên cả ba tập test. Điểm $s(x)$ được tính độc lập với văn bản sinh ra, nên vẫn có cả khi câu trả lời không parse được. CNN dùng điểm gốc của chúng: xác suất sigmoid (B1) và điểm box cao nhất của ảnh (B2).



Hình 5. Cách tính điểm liên tục $s(x)$ cho VLM và chọn ngưỡng. Trái: hai câu trả lời ép buộc dùng chung ảnh, câu hỏi và tiền tố; hiệu log-xác suất qua hàm sigmoid cho $s(x)$. Phải (minh hoạ, không phải kết quả): t_{90} đặt sao cho 90% ảnh âm của validation có điểm dưới ngưỡng; ảnh dương có điểm trên ngưỡng được tính là phát hiện.

Câu trả lời không parse được. Khi tính sensitivity và specificity thô, câu trả lời không parse được tính là "no". Riêng các chỉ số chế độ báo bình thường (tỷ lệ "no" trên ca dương, "yes" trên ca âm) chỉ tính trên câu trả lời parse được, và tỷ lệ không parse được được báo riêng. Mọi chỉ số được tính lại từ văn bản thô bằng parser hiện hành.

Sinh văn bản. C0 dùng giải mã tham lam (nhiệt độ 0) cho dòng kết quả chính, tối đa 256 token. Hai lần chạy ở nhiệt độ 0,7 chỉ dùng để đo độ ổn định: tỷ lệ đồng thuận trên các ảnh parse được ở mọi lần chạy.

3.6 Huấn luyện

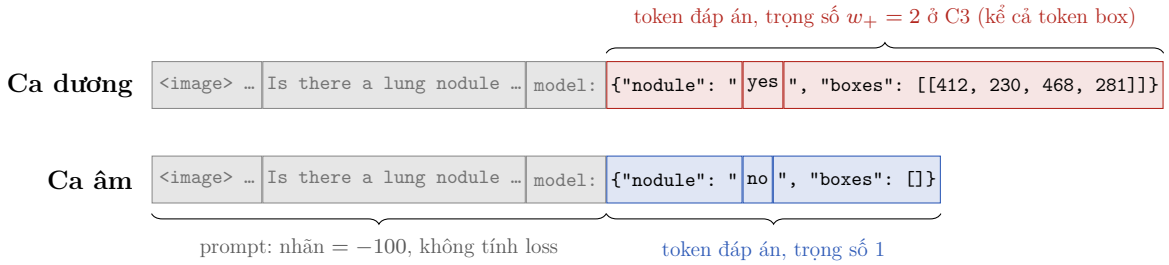
- SFT với loss chỉ tính trên token câu trả lời; tối ưu AdamW, learning rate 10^{-4}, lịch cosine, warmup 3%, 3 epoch, batch hiệu dụng 8 (batch 1 × tích luỹ gradient 8), bf16, gradient checkpointing.
- C1, C2 dùng tỷ lệ tự nhiên sau khi giảm bớt ảnh âm (tối đa 4 ảnh âm cho mỗi ảnh dương, cờ `--neg-per-pos 4`); C3 thêm oversampling ca dương 1:1 (`--balance`) và trọng số loss $w_+ = 2$ cho ca dương (`--pos-weight 2.0`, cố định theo `RUNBOOK.md`). w_+ áp lên mọi token đáp án của ca dương, kể cả token box. Loss được chuẩn hoá theo tổng số token nhãn trong cả cửa sổ tích luỹ gradient, để w_+ vẫn có tác dụng khi batch bằng 1 (Hình 6).
- Mỗi cấu hình C1–C3 chạy 3 seed; C4 chạy 1–3 seed; B1, B2 mỗi loại 3 seed.
- Ngưỡng chọn trên validation; mỗi tập test chỉ dùng một lần. Cấu hình áp cho C4 và cho kiểm toán E5 được chọn theo `val_sens90` (sensitivity trên validation tại ngưỡng

t_{90} của chính lần chạy đó) trung bình qua các seed, đọc từ `val_selection.csv`; không bao giờ dựa trên test.

Hình 6 cho thấy một mẫu huấn luyện sau khi ghép chuỗi. Toàn bộ token của mẫu chat (token ảnh, câu hỏi, tiền tố vai trò) được gán nhãn -100 nên không đóng góp vào loss. Chỉ token của câu trả lời JSON được tính. Với một cửa sổ tích luỹ gradient $\mathcal{W}$ gồm 8 mẫu, loss là

$$\mathcal{L}_{\mathcal{W}} = \frac{\sum_{i\in\mathcal{W}} w_i \sum_{t\in\mathcal{A}_i} -\log p_\theta(y_{i,t} \mid y_{i,<t}, x_i, q)}{\sum_{i\in\mathcal{W}} |\mathcal{A}_i|}, \qquad w_i = \begin{cases} w_+ & \text{nếu ca dương (C3)} \\ 1 & \text{ngược lại,} \end{cases} \tag{5}$$

trong đó $\mathcal{A}_i$ là tập vị trí token đáp án của mẫu i. Ở C1 và C2, mọi $w_i = 1$.



Hình 6. Định dạng một mẫu huấn luyện và mặt nạ loss (minh hoạ; số token ảnh và mẫu chat phụ thuộc mô hình). Ô xám: token ảnh, câu hỏi và tiền tố vai trò, bị loại khỏi loss. Ô màu: token đáp án được tính loss; ở C3, mọi token đáp án của ca dương nhân với w_+. Loss chia cho tổng số token nhãn của cả cửa sổ tích luỹ gradient.

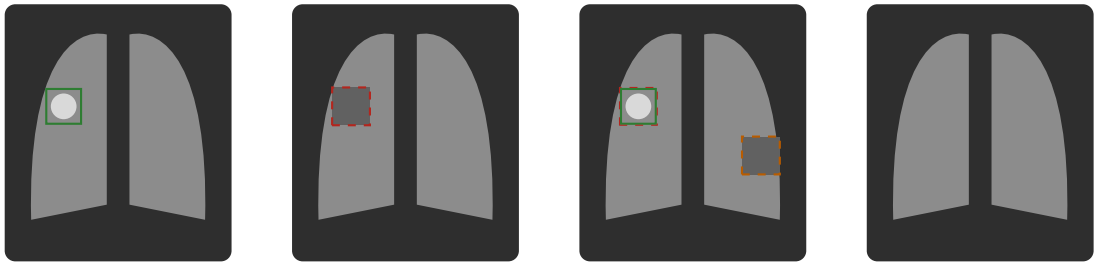
Ngân sách tính toán. Huấn luyện trên Colab. MedGemma chỉ chạy được trên GPU có compute capability ≥ 8 (L4 hoặc A100, bf16 thật), vì fp16 bị tràn số. Lượt LoRA đầu tiên dùng để đo thời gian. Nếu một lượt MedGemma-4B vượt 3 giờ, cắt giảm theo thứ tự: giảm số ảnh âm (giữ toàn bộ ảnh dương), giảm độ phân giải (chỉ với Qwen2.5-VL; processor của MedGemma cố định 896 px), giảm còn 2 epoch, giảm C1 còn 1 seed.

3.7 Kiểm toán "nhìn đúng chỗ"

Một trợ lý trả lời đúng nhưng nhìn sai chỗ (ví dụ dựa vào dấu hiệu máy chụp hay nhãn chữ trên phim) là không an toàn [23, 24]. Kiểm toán chạy trên mọi ảnh dương của `test` (VinBigData) và `test_jsrt`, với ba phép thử ở Bảng 3 và Hình 7. Một ảnh được coi là "yes" khi $s(x) \geq t_{90}$, với t_{90} lấy từ `thresholds.json` của đúng cấu hình đó (seed 0, run 0).

Bảng 3. Các phép thử phụ thuộc thị giác.

Mã	Phép thử	Hành vi mong đợi
T1	Che nốt: box nới 10% (5% mỗi cạnh), tô bằng giá trị trung bình của ảnh	Đáp án đổi từ "yes" sang "no"
T2	Che vùng ngẫu nhiên cùng kích thước với box đã nới, không giao vùng T1, $\geq 90\%$ diện tích nằm trong mặt nạ phổi (PSPNet của TorchXRayVision, dự phòng bằng mặt nạ heuristic)	Đáp án giữ nguyên
T3	Thay bằng một ảnh âm chọn ngẫu nhiên trong cùng tập test	"no" (báo tỷ lệ "yes")



$$\Delta_{\text{occ}} = \underbrace{\frac{\#\{\text{yes} \to \text{no ở T1}\}}{\#\{\text{yes ở ảnh gốc}\}}}_{\text{flip_t1}} - \underbrace{\frac{\#\{\text{yes} \to \text{no ở T2}\}}{\#\{\text{yes ở ảnh gốc}\}}}_{\text{flip_t2}}$$

trên cùng n_{T2} ảnh dương lấy mẫu được vùng T2

Hình 7. Minh hoạ ba phép thử của kiểm toán "nhìn đúng chỗ" (ảnh giản lược). Khung xanh: box nốt tham chiếu; khung đỏ nét đứt: vùng T1 (box nới 10%); khung cam nét đứt: vùng T2 cùng kích thước, $\geq 90\%$ nằm trong mặt nạ phổi. Δ_{occ} là hiệu tỷ lệ đổi đáp án giữa T1 và T2, tính bắt cặp trên cùng tập ảnh.

Chỉ số chính là Δ_{occ} = tỷ lệ đổi đáp án ở T1 − tỷ lệ đổi ở T2. Tỷ lệ đổi đáp án là phần các ảnh có đáp án "yes" ở ảnh gốc chuyển thành "no" sau khi che. Cả hai vế tính trên cùng tập con bắt cặp gồm các ảnh lấy mẫu được vùng T2, nên phải báo kèm số ảnh n_{T2} (khoá `n_t2_ok`, `delta` trong file `audit/*.json`). Tỷ lệ đổi ở T1 trên toàn bộ ca dương (`flip_t1_all`) chỉ để tham khảo. Δ_{occ} lớn cho thấy quyết định dựa vào vùng nốt; $\Delta_{\text{occ}} \approx 0$ cho thấy mô hình nhạy với mọi nhiễu loạn chứ không riêng nốt. T3 báo tỷ lệ "yes" trên ảnh tráo (`yes_rate_t3`), mong đợi gần $1-0{,}90 = 0{,}10$. Kết quả được phân tầng theo kích thước nốt và theo độ mờ JSRT 1–5. Với VinBigData và NIH, kích thước chia theo tertile diện tích box tương đối (ngưỡng lấy từ ca dương của tập train VinBigData, lưu ở `e0_data_edges.json`); với JSRT, chia theo mm: ≤ 10, 10–20 và > 20 mm. Kiểm toán áp cho C0-MedGemma, cấu hình LoRA tốt nhất theo `val_selection.csv` (adapter seed 0) và B2 (trọng số seed 0).

4 Dữ liệu

4.1 Các bộ dữ liệu

Bảng 4. Vai trò của từng bộ dữ liệu.

Vai trò	Bộ dữ liệu	Nhãn dùng và ghi chú
Huấn luyện, validation, test trong phân phối	VinBigData / VinDr-CXR [32]	15.000 ảnh huấn luyện, box theo từng bác sĩ (3 bác sĩ/ảnh). Dương: có ít nhất một box "Nodule/Mass"; âm: mọi ảnh còn lại, gồm cả ảnh "No finding" và ảnh có bệnh khác (âm khó).
Test ngoài phân phối 1	NIH ChestX-ray14 [33]	Dương: các ảnh có box Nodule hoặc Mass trong `BBox_List_2017.csv` (tập con khoảng 1.000 ảnh có box cho 8 bệnh). Âm: ảnh "No Finding" của bệnh nhân không có ảnh dương, lấy ngẫu nhiên gấp 3 lần số ảnh dương (`--neg-ratio 3`). Nhãn "No Finding" rút từ báo cáo nên có nhiễu.
Test ngoài phân phối 2 (độ mờ)	JSRT [34]	247 ảnh, 154 có nốt kèm vị trí, kích thước (mm), độ mờ 1–5, lành/ác. Cho phép so trực tiếp với [3].
Chỉ tham khảo	NODE21 [35]	Trùng nguồn với JSRT và NIH nên không dùng làm test, để tránh rò rỉ.

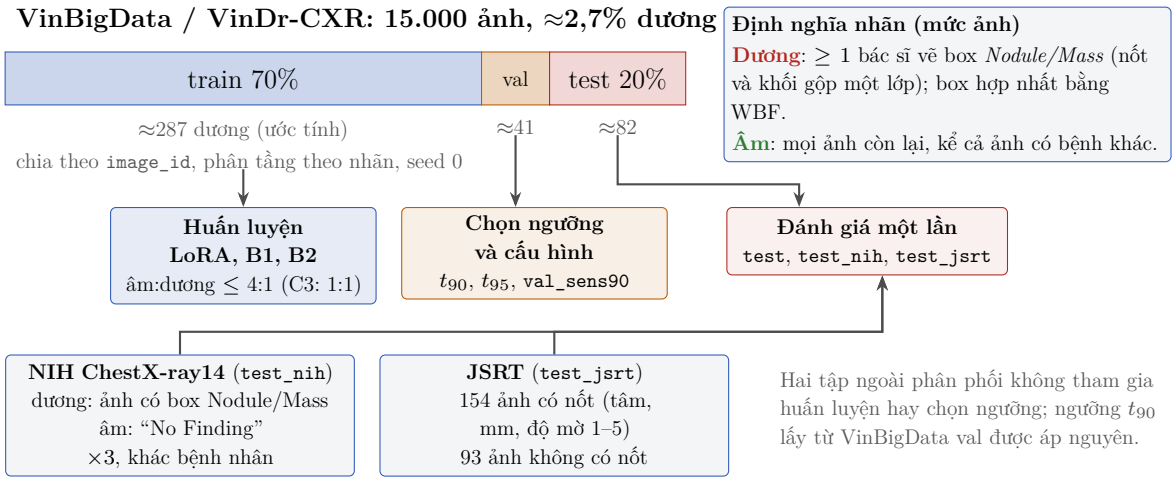
Trước khi dùng, nhóm phải kiểm tra điều khoản của cuộc thi VinBigData trên Kaggle, giấy phép NIH và JSRT, và chấp nhận điều khoản Health AI Developer Foundations để tải MedGemma. Ảnh không được phân phối lại; đồ án chỉ bàn giao nhãn và dự đoán.

4.2 Gán nhãn và hợp nhất box

Mỗi ảnh VinBigData được 3 bác sĩ gán nhãn độc lập. Ảnh là dương nếu có ít nhất một box Nodule/Mass. Box của các bác sĩ được hợp nhất bằng WBF [45] để có một box tham chiếu cho mỗi tổn thương. Nốt và khối được gộp thành một lớp dương; vì khối lớn trên 3 cm dễ phát hiện hơn nhiều, kết quả được phân tầng theo kích thước để tránh việc khối lớn che lấp hiệu năng trên nốt nhỏ.

4.3 Chia dữ liệu

VinBigData được chia theo `image_id`, tỷ lệ 70/10/20, phân tầng theo nhãn Nodule/Mass, với seed cố định (`prepare_vinbig.py --seed 0`). Bản VinBigData trên Kaggle không kèm mã bệnh nhân, nên không chia được theo bệnh nhân; nếu một bệnh nhân có nhiều ảnh, các ảnh đó có thể rơi vào cả train và test (một hạn chế, xem Mục 6). Ngưỡng và lựa chọn cấu hình chỉ dùng validation. NIH và JSRT chỉ dùng làm test. Hình 8 tóm tắt cách chia, vai trò của từng tập và định nghĩa ca dương.



Hình 8. Chia dữ liệu và định nghĩa nhãn. VinBigData chia 70/10/20 theo ảnh; validation chỉ dùng để chọn ngưỡng và cấu hình; ba tập test (một trong phân phối, hai ngoài phân phối) chỉ được đánh giá một lần. Số ca dương là ước tính từ [32]; số thật lấy từ `e0_data.md` sau E0.

Rủi ro cỡ mẫu. Tập huấn luyện của VinDr-CXR chỉ có 410/15.000 ảnh Nodule/Mass (2,73%) [32]. Chia 70/10/20 còn khoảng 287 / 41 / 82 ảnh dương (ước tính), nên khoảng tin cậy của sensitivity trên test sẽ rộng (với 82 ca dương và sensitivity 0,60, nửa độ rộng CI 95% xấp xỉ ±0,11). Nếu truy cập được, đồ án ưu tiên dùng tập test chính thức của VinDr-CXR (3.000 ảnh, 176 ảnh Nodule/Mass, nhãn đồng thuận 5 bác sĩ).

4.4 Tiền xử lý

- DICOM (VinBigData), PNG (NIH) và ảnh thô 12-bit (JSRT) được chuẩn hoá cường độ, chuyển thành PNG xám 896×896; hệ số quy đổi toạ độ được lưu lại để đổi box về ảnh gốc.
- Qwen2.5-VL được ép cùng số pixel (896 × 896) để hai VLM nhận cùng đầu vào.
- Kích thước nốt quy đổi theo diện tích box tương đối; riêng JSRT có kích thước tính bằng mm.

4.5 Thống kê mô tả

Bảng 5 được điền từ `outputs/e0_data.md` (sinh bởi `data_stats.py` ở E0).

Bảng 5. Thống kê dữ liệu sau tiền xử lý (điền sau E0).

Tập	Số ảnh	Dương	Tỷ lệ dương	Diện tích box trung vị
VinBigData train	[–]	[–]	[–]	[–]
VinBigData val	[–]	[–]	[–]	[–]
VinBigData test	[–]	[–]	[–]	[–]
NIH ChestX-ray14 (test)	[–]	[–]	[–]	[–]
JSRT (test)	247	154	62%	[–]

5 Thí nghiệm, đánh giá và kết quả

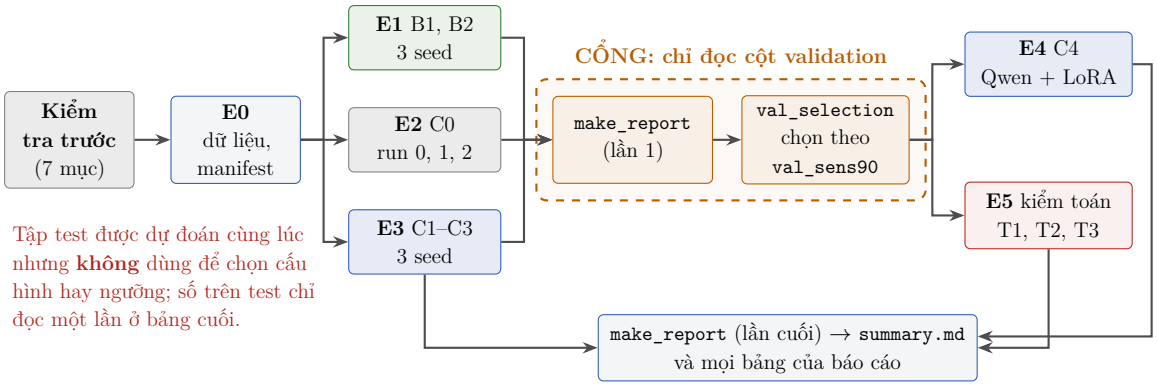
> **Trạng thái.** Báo cáo đang ở giai đoạn đề cương: thiết kế thí nghiệm và cách đánh giá đã chốt, mã nguồn (gói `nodulecxr`) đã cài đặt xong và qua 75 kiểm thử trên CPU; các bước cần GPU chưa chạy, nên chưa có kết quả. Các ô [–] sẽ được điền tự động từ file dự đoán sau khi chạy E0–E5.

5.1 Thiết kế thí nghiệm

Bảng 6 liệt kê sáu thí nghiệm; Hình 9 cho thứ tự chạy và các phụ thuộc. Các thí nghiệm phải chạy đúng thứ tự này. E4 và E5 phụ thuộc vào cấu hình được chọn, và cấu hình đó chỉ được chọn từ `val_selection.csv`, file do `make_report.py` sinh ra sau E3. Lệnh cụ thể của từng bước nằm trong `code/RUNBOOK.md`; Phụ lục A tóm tắt đầu vào, đầu ra và bảng mà mỗi bước điền.

Bảng 6. Các thí nghiệm.

Mã	Nội dung	Kết quả cần có
E0	Chuẩn bị dữ liệu: số ca Nodule/Mass, phân bố kích thước box, độ đồng thuận giữa bác sĩ; hợp nhất box	Bảng 5
E1	Baseline B1, B2 trên VinBigData, đánh giá trên 3 tập test, mỗi loại 3 seed	AUC, sens@spec0,90, FROC
E2	Zero-shot C0 cho MedGemma-4B và Qwen2.5-VL-3B: 1 lần nhiệt độ 0 (dòng chính) và 2 lần nhiệt độ 0,7 (đo độ ổn định)	Bảng zero-shot, tỷ lệ parse lỗi, tỷ lệ đồng thuận
E3	LoRA C1, C2, C3 trên MedGemma-4B, mỗi cấu hình 3 seed	Bảng so sánh, đường học, sensitivity theo epoch
E4	C4: cấu hình tốt nhất áp lên Qwen2.5-VL-3B, 1–3 seed	So sánh mô hình y khoa với mô hình đa năng
E5	Kiểm toán "nhìn đúng chỗ" (Mục 3.7) cho C0, cấu hình LoRA tốt nhất và B2; phân tầng	Bảng đổi đáp án, sensitivity theo tầng



Hình 9. Thứ tự chạy thí nghiệm. E1–E3 độc lập với nhau sau E0. `make_report.py` lần 1 sinh `val_selection.csv` và `thresholds.json`; cổng chọn (khung cam) chỉ dùng số trên validation để chọn cấu hình LoRA tốt nhất cho E4 và E5. Lần chạy cuối của `make_report.py` gộp mọi file dự đoán thành bảng báo cáo.

5.2 Chỉ số đánh giá

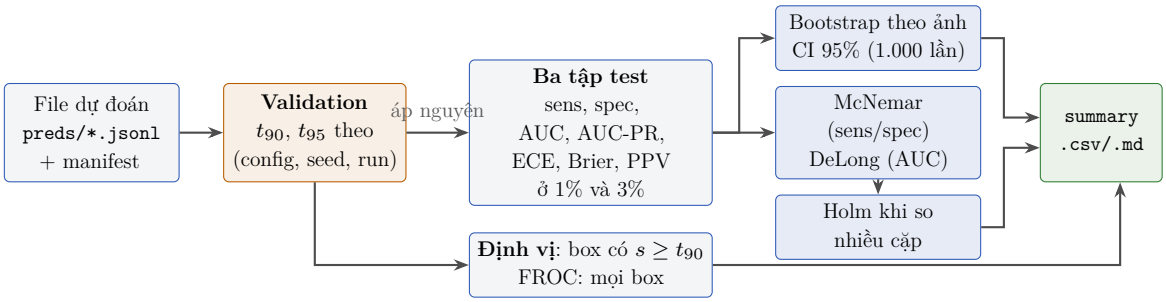
Phát hiện mức ảnh.

- Sensitivity, specificity, PPV, NPV, F1; AUC-ROC và AUC-PR.
- **Chỉ số chính:** sensitivity ở specificity 0,90 (và 0,95). Ngưỡng t_{90}, t_{95} chọn trên validation, riêng cho từng bộ (cấu hình, seed, lần chạy), rồi áp nguyên lên cả ba tập test. **Tiêu chí thành công:** sensitivity $\geq$ 0,60 ở specificity 0,90 trên VinBigData test.
- **Chỉ số trên văn bản sinh ra** (chỉ có với VLM chạy `--generate all`): `raw_sens/raw_spec` tính trên mọi ảnh, câu trả lời không parse được tính là "no". Các chỉ số chế độ báo bình thường, `no_on_pos` (tỷ lệ "no" trên ca dương) và `yes_on_neg` (tỷ lệ "yes" trên ca âm), chỉ tính trên câu trả lời parse được. Tỷ lệ không parse được (`unparsed`) báo riêng. Mọi chỉ số này được tính lại từ `raw_text` bằng parser hiện hành.
- **C0:** dòng chính chỉ dùng run 0 (nhiệt độ 0, tối đa 256 token). Run 1–2 (nhiệt độ 0,7) chỉ dùng cho tỷ lệ đồng thuận trong `run_agreement.csv`, tính trên các ảnh parse được ở mọi lần chạy.
- **Theo tỷ lệ bệnh** [20, 16]: ECE, Brier và balanced Brier; PPV quy về tỷ lệ bệnh 1% và 3%. Trên JSRT tỷ lệ nốt là 62%, nên PPV ở đó không có ý nghĩa lâm sàng.

Định vị. IoU trung bình và tỷ lệ "đúng và IoU $\geq$ 0,3" (ngưỡng thấp vì nốt nhỏ; báo thêm ở 0,5) chỉ dùng các box có điểm $\geq t_{90}$, ngưỡng ứng với specificity 0,90 (box của VLM mang điểm của ảnh). FROC dùng mọi box, áp cho B2 và các VLM có box. Trên JSRT, chỉ xét box có điểm cao nhất; "trúng" khi tâm box nằm trong bán kính nốt cộng biên 5 mm (12,5 px trên ảnh 896); báo thêm khoảng cách tâm trung vị (mm, quy đổi 0,4 mm/px), theo cách của NoduLoCC [36].

Phân tầng. Sensitivity được báo theo tầng kích thước (`strata.csv`): VinBigData và NIH theo tertile diện tích box tương đối, ngưỡng tertile lấy từ ca dương train VinBigData (`e0_data_edges.json`); JSRT theo mm: ≤ 10, 10–20, > 20 mm; thêm theo độ mờ JSRT 1–5.

Thống kê. Trung bình ± độ lệch chuẩn qua các seed; CI 95% bằng bootstrap theo ảnh (1.000 lần lấy mẫu lại), phân tầng theo nhãn (CI theo từng seed lưu trong `summary_per_seed.csv`); McNemar cho sens/spec, DeLong cho AUC, hiệu chỉnh Holm khi so nhiều cặp (`comparisons.csv`). Bootstrap lấy mẫu theo ảnh, không gộp theo bệnh nhân, nên CI có thể hẹp hơn thực tế nếu một bệnh nhân có nhiều ảnh; đây là một hạn chế. Hình 10 tóm tắt luồng đánh giá.



Hình 10. Luồng đánh giá và thống kê trong `make_report.py`. Ngưỡng chỉ chọn trên validation rồi áp nguyên lên test; chỉ số định vị dùng box có điểm $\geq t_{90}$; khoảng tin cậy bằng bootstrap theo ảnh; so sánh bắt cặp bằng McNemar và DeLong, hiệu chỉnh Holm.

5.3 Kết quả chính

Bảng 7. Sensitivity ở specificity 0,90 và AUC-ROC trên ba tập test, trung bình ± độ lệch chuẩn qua seed (điền từ `outputs/report/summary.md` sau E1–E4; C0 chỉ dùng run 0). Mục tiêu: sens@spec0,90 $\geq$ 0,60 trên VinBigData test.

	VinBigData		NIH		JSRT	
Cấu hình	Sens@0,90	AUC	Sens@0,90	AUC	Sens@0,90	AUC
C0 MedGemma-4B	[–]	[–]	[–]	[–]	[–]	[–]
C0 Qwen2.5-VL-3B	[–]	[–]	[–]	[–]	[–]	[–]
C1 LoRA, phân loại	[–]	[–]	[–]	[–]	[–]	[–]
C2 LoRA, + box	[–]	[–]	[–]	[–]	[–]	[–]
C3 LoRA, + box, cân bằng	[–]	[–]	[–]	[–]	[–]	[–]
C4 Qwen2.5-VL-3B LoRA	[–]	[–]	[–]	[–]	[–]	[–]
B1 DenseNet-121	[–]	[–]	[–]	[–]	[–]	[–]
B2 YOLOv8	[–]	[–]	[–]	[–]	[–]	[–]

Mốc tham chiếu từ tài liệu. Zero-shot trên JSRT, MedGemma-4b-it đạt sensitivity 5,2% ở specificity 100% và LLaVA-Rad đạt 27,3% ở specificity 71,0% [3]. Các số này dùng đầu ra nhị phân, không ở điểm vận hành specificity 0,90, nên chỉ để định hướng.

5.4 Định vị

Bảng 8. Chỉ số định vị (điền từ `summary.md` sau E1–E4). IoU và Hit chỉ tính trên box có điểm $\geq t_{90}$; JSRT dùng box điểm cao nhất, "trúng" khi tâm cách tâm nốt $\leq$ bán kính nốt + 5 mm.

	VinBigData test			JSRT
Cấu hình	IoU TB	Hit@IoU0,3	Hit@IoU0,5	Khoảng cách tâm trung vị (mm)
C0 Qwen2.5-VL-3B	[–]	[–]	[–]	[–]
C2 / C3 (tốt nhất)	[–]	[–]	[–]	[–]
C4	[–]	[–]	[–]	[–]
B2 YOLOv8	[–]	[–]	[–]	[–]

5.5 Chế độ báo bình thường và tác dụng của cân bằng lớp

So sánh C2 với C3 theo `no_on_pos`, `yes_on_neg`, `unparsed`, sensitivity theo epoch (dự đoán `--config <cfg>-ep<k>` trên val cho từng checkpoint của seed 0) và calibration (ECE, balanced Brier). [Điền sau E3: bảng từ `summary.md` và đường học.]

5.6 Kiểm toán "nhìn đúng chỗ"

Bảng 9. Tỷ lệ đổi đáp án dưới các phép thử che vùng (điền từ `outputs/audit/*.json` sau E5; một bảng cho `test`, một cho `test_jsrt`).

Cấu hình	T1 (`flip_t1`)	T2 (`flip_t2`)	Δ_{occ} (n_{T2})	T3: tỷ lệ "yes"
C0 MedGemma-4B	[–]	[–]	[–]	[–]
LoRA tốt nhất	[–]	[–]	[–]	[–]
B2 YOLOv8	[–]	[–]	[–]	[–]

[Điền sau E5 từ `strata.csv` và khoá `by_size`/`by_subtlety` của `audit/*.json`: biểu đồ sensitivity theo tầng kích thước (tertile diện tích với VinBigData/NIH; $\leq$ 10, 10–20, $>$ 20 mm với JSRT) và theo độ mờ JSRT 1–5.]

6 Kết luận, hạn chế và hướng phát triển

6.1 Kết luận

[Điền sau E1–E5: trả lời Q1 (LoRA có đạt sens@spec0,90 $\geq$ 0,60 trên VinBigData test không) và Q2 (cải thiện có còn trên JSRT và khi che nốt không), theo cả hai hướng có thể xảy ra.]

Dù kết quả theo hướng nào, đồ án sẽ đóng góp một benchmark có kiểm soát cho VLM trên bài toán nốt phổi, một phân tích định lượng về chế độ báo bình thường khi tinh chỉnh với lớp dương hiếm, và một quy trình kiểm toán "nhìn đúng chỗ" dùng được cho các trợ lý đọc ảnh khác.

6.2 Hạn chế

- **Nhãn có nhiễu:** nhãn NIH rút từ báo cáo; nhãn VinBigData có bất đồng giữa các bác sĩ.
- **Cỡ mẫu nhỏ:** khoảng 82 ảnh dương ở tập test VinBigData, nên khoảng tin cậy rộng.
- **Bootstrap theo ảnh, không gộp theo bệnh nhân:** nếu một bệnh nhân có nhiều ảnh, khoảng tin cậy có thể hẹp hơn thực tế.
- **Chia VinBigData theo ảnh:** bản Kaggle không có mã bệnh nhân, nên ảnh của cùng một bệnh nhân (nếu có) có thể nằm ở cả train và test, làm kết quả trong phân phối lạc quan hơn.
- **Thiếu kích thước thật:** VinBigData không có kích thước nốt tính bằng mm; chỉ JSRT có.
- **Ngoài phân phối mạnh:** JSRT là phim scan cũ.
- **Mô hình cỡ nhỏ**, bộ mã hoá ảnh đông cứng; kết luận không tự động mở rộng sang VLM lớn.
- **Không có mô bệnh học:** trợ lý phát hiện nốt/khối, không phân biệt lành/ác (trừ phân tích phụ trên JSRT).
- **Rò rỉ dữ liệu:** MIMIC-CXR, VinDr-CXR và NIH được tái dùng rộng rãi để huấn luyện VLM [37, 38], nên kết quả zero-shot trên các tập này có thể bị thổi phồng. JSRT ít bị dùng hơn nhưng không đảm bảo hoàn toàn.

6.3 An toàn và đạo đức

Một trợ lý yếu nhưng trả lời tự tin có thể kéo người đọc theo hướng sai [23, 24]. Vì vậy kiểm toán "nhìn đúng chỗ" có ý nghĩa an toàn, không chỉ học thuật. **Trợ lý trong đồ án là nguyên mẫu nghiên cứu, không dùng cho quyết định lâm sàng** và không

được trình bày như công cụ sẵn sàng triển khai. Đồ án chỉ dùng dữ liệu công khai đã ẩn danh và không phân phối lại ảnh.

6.4 Hướng phát triển

- **VLM có hỗ trợ vùng (C5):** detector đề xuất vùng, VLM xác nhận và giải thích, theo kiểu agent MedRAX [7].
- **Từ phát hiện đến báo cáo và theo dõi:** sinh câu mô tả nốt (vị trí, kích thước, tính chất) và gợi ý chụp CT theo guideline Fleischner, có RAG; các LLM hiện vẫn áp guideline chưa đáng tin cậy [8].
- **Nguy cơ ung thư đa phương thức:** kết hợp CXR với dữ liệu lâm sàng, so với CXR-LC [11].
- **Câu hỏi mở:** bộ mã hoá ảnh đông cứng có phải nút thắt không? Cần thí nghiệm mở khoá một phần bộ mã hoá, hoặc probe patch-local trên mô hình sau LoRA.

Tài liệu tham khảo

[1] F. Bray et al. Global cancer statistics 2022: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries. *CA: A Cancer Journal for Clinicians*, 74(3):229–263, 2024.

[2] D. Khovanova et al. A comparative accuracy study of multimodal LLMs, VLM and agent-based framework for pulmonary nodule detection on chest radiographs. *Frontiers in Digital Health*, 2026. doi:10.3389/fdgth.2025.1674835.

[3] M. Nishio et al. Zero-shot performance of six vision-language models for lung nodule detection on chest radiographs. *American Journal of Roentgenology*, 2026. doi:10.2214/AJR.26.35421.

[4] C.-H. Chen et al. Limitations in chest X-ray interpretation by vision-capable LLMs: Gemini 1.0, Gemini 1.5 Pro, GPT-4 Turbo, and GPT-4o. *Diagnostics*, 16(3):376, 2026. doi:10.3390/diagnostics16030376.

[5] A. Cusick et al. The effect of structured context on CXR interpretation by a multimodal LLM: a pilot comparative study. *Cureus*, 2026. doi:10.7759/cureus.108715.

[6] A. Sellergren et al. An open vision-language model for diverse medical applications (MedGemma). *Nature Medicine*, 2026. doi:10.1038/s41591-026-04626-w.

[7] A. Fallahpour et al. MedRAX: Medical reasoning agent for chest X-ray. *arXiv preprint arXiv:2502.02673*, 2025.

[8] J. L. Gamble et al. Limitations of GPT-3.5 and GPT-4 in applying Fleischner Society guidelines to incidental lung nodules. *Canadian Association of Radiologists Journal*, 2024. doi:10.1177/08465371231218250.

[9] J. G. Nam et al. Development and validation of deep learning-based automatic detection algorithm for malignant pulmonary nodules on chest radiographs. *Radiology*, 290(1):218–228, 2019. doi:10.1148/radiol.2018180237.

[10] J. G. Nam et al. AI improves nodule detection on chest radiographs in a health screening population: a randomized controlled trial. *Radiology*, 2023. doi:10.1148/radiol.221894.

[11] M. T. Lu et al. Deep learning using chest radiographs to identify high-risk smokers for lung cancer screening computed tomography. *Annals of Internal Medicine*, 173(9):704–713, 2020. doi:10.7326/M20-1868.

[12] K. Arzamasov et al. Independent evaluation of the accuracy of 5 artificial intelligence software for detecting lung nodules on chest X-rays. *Quantitative Imaging in Medicine and Surgery*, 2024. doi:10.21037/qims-24-160.

[13] E. Pesce et al. Learning to detect chest radiographs containing pulmonary lesions using visual attention networks. *Medical Image Analysis*, 53:26–38, 2019. doi:10.1016/j.media.2018.12.007.

[14] S. Jang et al. Deep learning-based automatic detection algorithm for reducing overlooked lung cancers on chest radiographs. *Radiology*, 296(3):652–661, 2020. doi:10.1148/radiol.2020200165.

[15] J. H. Lee et al. Performance of a deep learning algorithm compared with radiologic interpretation for lung cancer detection on chest radiographs in a health screening population. *Radiology*, 297(3):687–696, 2020. doi:10.1148/radiol.2020201240.

[16] Kim et al. Multicentre external validation of a commercial artificial intelligence software to analyse chest radiographs in health screening environments with low disease prevalence. *European Radiology*, 2023. doi:10.1007/s00330-022-09315-z.

[17] K. G. van Leeuwen et al. Comparison of commercial AI software performance for radiograph lung nodule detection and bone age prediction. *Radiology*, 2024. doi:10.1148/radiol.230981.

[18] C. F. Sabottke and B. M. Spieler. The effect of image resolution on deep learning in radiography. *Radiology: Artificial Intelligence*, 2(1):e190015, 2020. doi:10.1148/ryai.2019190015.

[19] Kim et al. Optimal matrix size of chest radiographs for computer-aided detection on lung nodule or mass with deep learning. *European Radiology*, 2020. doi:10.1007/s00330-020-06892-9.

[20] C. Mosquera et al. Class imbalance on medical image classification: towards better evaluation practices for discrimination and calibration performance. *European Radiology*, 2024. doi:10.1007/s00330-024-10834-0.

[21] Y. Sim et al. Deep convolutional neural network-based software improves radiologist detection of malignant lung nodules on chest radiographs. *Radiology*, 294(1):199–209, 2020. doi:10.1148/radiol.2019182465.

[22] J. S. Ahn et al. Association of artificial intelligence-aided chest radiograph interpretation

with reader performance and efficiency. *JAMA Network Open*, 5(8):e2229289, 2022. doi:10.1001/jamanetworkopen.2022.29289.

[23] M. H. Bernstein et al. Can incorrect artificial intelligence (AI) results impact radiologists, and if so, what can we do about it? *European Radiology*, 2023. doi:10.1007/s00330-023-09747-1.

[24] J. H. Lee et al. Human–AI interaction in the detection of malignant lung nodules on chest radiographs. *Radiology*, 2023. doi:10.1148/radiol.222976.

[25] Muthyala et al. Frozen foundation-model embeddings discard small-lesion signal in chest radiography. *arXiv preprint arXiv:2606.11606*, 2026.

[26] Gosai et al. Beyond diagnosis: evaluating multimodal LLMs for pathology localization in chest radiographs. In *Machine Learning for Health (ML4H), PMLR*, 2025. arXiv:2509.18015.

[27] Choi et al. CheXpercept: expert-level lesion perception in chest X-rays. *arXiv preprint arXiv:2606.21020*, 2026.

[28] Fisher. Vision-language foundation models do not transfer to medical imaging classification. *medRxiv preprint*, 2025. doi:10.64898/2025.12.06.25341759.

[29] E. Volkov. VLM fine-tuning via LoRA for structured reports on lung X-ray. In *IEEE International Conference on Soft Computing and Measurements (SCM)*, 2025. doi:10.1109/scm66446.2025.11060140.

[30] J. Gao et al. S2D-Align: anatomically grounded radiology report generation. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 2026. doi:10.1609/aaai.v40i36.40335.

[31] Xu et al. MedGround-R1: advancing medical image grounding via spatial-semantic rewarded group relative policy optimization. In *MICCAI*, 2025. doi:10.1007/978-3-032-04971-1_37.

[32] H. Q. Nguyen et al. VinDr-CXR: an open dataset of chest X-rays with radiologist's annotations. *Scientific Data*, 9:429, 2022. doi:10.1038/s41597-022-01498-w.

[33] X. Wang, Y. Peng, L. Lu, Z. Lu, M. Bagheri, and R. M. Summers. ChestX-ray8: hospital-scale chest X-ray database and benchmarks on weakly-supervised classification and localization of common thorax diseases. In *Proceedings of CVPR*, pages 2097–2106, 2017.

[34] J. Shiraishi et al. Development of a digital image database for chest radiographs with and without a lung nodule. *American Journal of Roentgenology*, 174(1):71–74, 2000.

[35] E. Sogancioglu et al. Nodule detection and generation on chest X-rays: NODE21 Challenge. *IEEE Transactions on Medical Imaging*, 2024. arXiv:2401.02192.

[36] A. Mustafic et al. NoduLoCC2026: lung nodule localization and classification contest from chest X-ray images. *arXiv preprint arXiv:2606.21290*, 2026.

[37] A. E. W. Johnson et al. MIMIC-CXR-JPG, a large publicly available database of labeled chest radiographs. *arXiv preprint arXiv:1901.07042*, 2019.

[38] D. H. Nguyen et al. VinDr-CXR-VQA: a VQA dataset for explainable chest X-ray analysis with multi-task learning. *arXiv preprint arXiv:2511.00504*, 2025.

[39] A. Dosovitskiy et al. An image is worth 16x16 words: transformers for image recognition at scale. In *International Conference on Learning Representations (ICLR)*, 2021.

[40] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen. LoRA: low-rank adaptation of large language models. In *International Conference on Learning Representations (ICLR)*, 2022.

[41] S. Bai et al. Qwen2.5-VL technical report. *arXiv preprint arXiv:2502.13923*, 2025.

[42] G. Huang, Z. Liu, L. van der Maaten, and K. Q. Weinberger. Densely connected convolutional networks. In *Proceedings of CVPR*, pages 4700–4708, 2017.

[43] J. P. Cohen et al. TorchXRayVision: a library of chest X-ray datasets and models. In *Medical Imaging with Deep Learning (MIDL), PMLR 172*, 2022.

[44] G. Jocher, A. Chaurasia, and J. Qiu. Ultralytics YOLOv8. Phần mềm, https://github.com/ultralytics/ultralytics, 2023.

[45] R. Solovyev, W. Wang, and T. Gabruseva. Weighted boxes fusion: ensembling boxes from different object detection models. *Image and Vision Computing*, 107:104117, 2021.

[46] E. R. DeLong, D. M. DeLong, and D. L. Clarke-Pearson. Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach. *Biometrics*, 44(3):837–845, 1988.

Phụ lục

A Quy trình thực nghiệm bắt buộc

Phụ lục này là quy trình nhóm thực hiện phải theo khi chạy E0–E5. Lệnh chính xác, đủ cờ, nằm trong `code/RUNBOOK.md`; khi phụ lục và RUNBOOK khác nhau về lệnh, theo RUNBOOK. Khi khác nhau về phương pháp, theo đề cương (`docs/design/2026-11-12-lung-nodule-cxr-vlm-lora-design.md`, mục 8.5). Năm quy tắc:

1. Chạy theo đúng thứ tự ở Hình 9. Không chạy E1–E5 khi còn mục kiểm tra trước chưa đạt.
2. Chỉ chọn ngưỡng và cấu hình trên validation, tức là từ hai file `thresholds.json` và `val_selection.csv`. Không mở cột test để chọn, kể cả khi số trên test "đẹp" hơn.
3. Không gõ tay số vào báo cáo. Mọi ô [–] chép từ file trong `outputs/` như Bảng 10.
4. Không xoá hay sửa tay file `outputs/preds/*.jsonl`. Script tự bỏ qua ảnh đã chạy, nên khi Colab ngắt chỉ cần chạy lại đúng lệnh cũ.
5. Ghi mọi quyết định ngân sách (cắt ảnh âm, giảm epoch, mặt nạ phổi heuristic, …) vào `outputs/budget.md`, và nêu lại trong báo cáo.

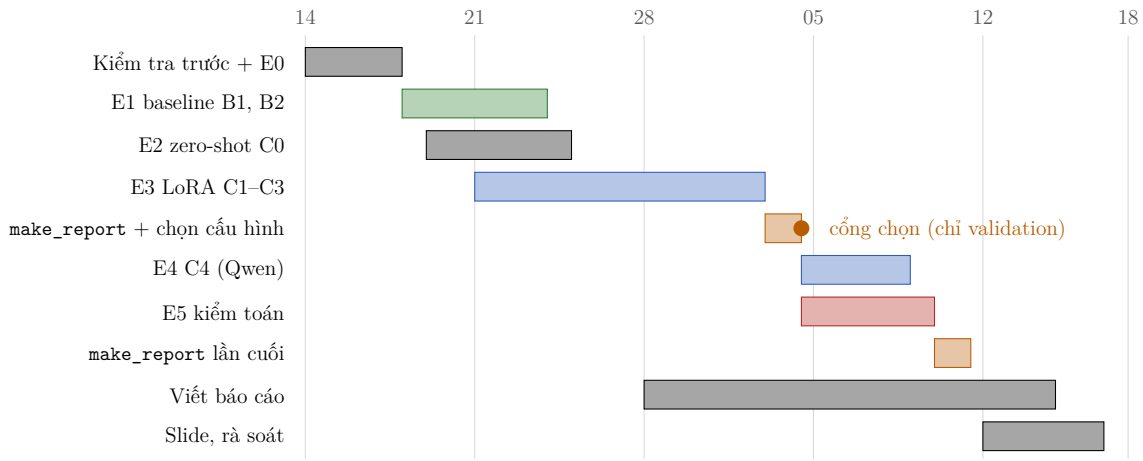
Kiểm tra bắt buộc trên Colab trước khi chạy đủ. Làm lần lượt; mục nào không đạt thì dừng và sửa (chi tiết trong mục "Kiểm tra bắt buộc" của `RUNBOOK.md`).

- ☐ **1. Tokenizer cho điểm yes/no** (với `medgemma` và `qwen`): sau điểm phân kỳ chỉ còn chính từ `yes`/`no`, không có dấu nháy bị gộp; target huấn luyện sau `ANSWER_PREFIX` bắt đầu bằng đúng token đó.
- ☐ **2. Một lần `build_example` cho mỗi model trên ảnh thật:** không ném `ValueError` ở bước kiểm tra tiền tố prompt của Gemma.
- ☐ **3. Loss đầu tiên của pilot 160 mẫu** (`--max-train 160 --epochs 1`): `loss` ở bước 10 khoảng 0,5–3. Nếu khoảng 10–25 thì gradient accumulation bị chia hai lần: dừng và sửa.
- ☐ **4. Loại GPU:** L4 hoặc A100, số đầu của `torch.cuda.get_device_capability()` ≥ 8. Không dựa vào `is_bf16_supported()` (T4 cũng trả `True`).
- ☐ **5. Smoke YOLO 1 epoch:** file `best.pt` được tạo ra.
- ☐ **6. Thời gian mặt nạ phổi** của `run_audit.py` trên 10 ảnh; nếu quá chậm dùng `--lung-mask heuristic` và ghi vào `budget.md`.
- ☐ **7. Thời gian suy luận VLM** trên 50 ảnh val (cấu hình `pilot`, ghi ra ngoài `outputs/preds/`); ghi giây/ảnh vào `budget.md` và ngoại suy chi phí C0.

Bảng 10. Đầu vào, lệnh, đầu ra của từng bước và chỗ trong báo cáo mà bước đó điền. Đường dẫn tương đối với thư mục gốc dự án; `M = data/processed`, `O = outputs`.

Bước	Đầu vào	Lệnh (RUNBOOK)	Đầu ra	Điền vào
Kiểm tra	Colab L4/A100, `HF_TOKEN`, `M/`	7 mục ở trên	`O/budget.md`	Ngân sách (Mục 3)
E0	Dữ liệu gốc VinBigData, NIH, JSRT	`prepare_vinbig.py`, `prepare_nih.py`, `prepare_jsrt.py`, `draw_boxes.py`, `data_stats.py`	`M/manifest_*.csv`, PNG 896, `O/qa/`, `O/e0_data.md`, `O/e0_data_edges.json`	Bảng 5; số ca ở Hình 8
E1	3 manifest, PNG	`train_densenet.py`, `train_yolo.py`, seed 0–2	`O/preds/B1.jsonl`, `B2.jsonl`, `O/yolo/seed*/weights/best.pt`	Dòng B1, B2 của Bảng 7; B2 ở Bảng 8
E2	3 manifest	`predict_vlm.py --config C0-medgemma|C0-qwen`, run 0 (T=0), run 1–2 (T=0,7), 256 token	`O/preds/C0-medgemma.jsonl`, `C0-qwen.jsonl`	Dòng C0 của Bảng 7, 8; `run_agreement.csv`
E3	`manifest_vinbig.csv`	`train_lora.py --mode cls|loc` (C3: `--balance --pos-weight 2.0`), seed 0–2; `predict_vlm.py --adapter`	`O/lora/C{1,2,3}-s*/final`, `timing.json`, `O/preds/C1|C2|C3.jsonl`, `<cfg>-ep<k>`	Dòng C1–C3 của Bảng 7, 8; mục chế độ báo bình thường
Báo cáo lần 1	`O/preds/*.jsonl`, `e0_data_edges.json`	`make_report.py`	`O/report/val_selection.csv`, `thresholds.json`, `summary.csv/.md`, `summary_per_seed.csv`, `strata.csv`, `comparisons.csv`, `run_agreement.csv`	Chọn cấu hình LoRA tốt nhất (trung bình `val_sens90`); ghi vào `budget.md`
E4	Cấu hình tốt nhất từ `val_selection.csv`	`train_lora.py --model qwen` cùng cờ; `predict_vlm.py --model qwen --config C4`	`O/lora/C4-s*`, `O/preds/C4.jsonl`	Dòng C4 của Bảng 7, 8
E5	t_{90} từ `thresholds.json` (khoá `cfg|0|0`), adapter seed 0, `best.pt` seed 0	`run_audit.py` trên `test` và `test_jsrt`, cho C0-medgemma, LoRA tốt nhất, B2	`O/audit/<cfg>_<split>.json` (`delta`, `n_t2_ok`, `flip_t1_all`, `yes_rate_t3`, `by_size`, `by_subtlety`)	Bảng 9; biểu đồ theo tầng
Báo cáo cuối	Toàn bộ `O/preds/`	`make_report.py` (chạy lại)	`O/report/summary.md` và các file trên	Mọi ô [–]; Tóm tắt; Kết luận (Q1, Q2)

Lịch dự kiến. Hình 11 là lịch đề xuất cho phần việc còn lại. Ngày tháng chỉ là đề xuất, nhóm điều chỉnh theo thời gian đo được ở kiểm tra mục 3 và 7.



Hình 11. Lịch **đề xuất** cho phần việc còn lại, từ 14/11 đến 18/12/2026; chưa phải lịch đã chốt. Màu theo loại việc như các hình trước: xanh lá baseline, xám zero-shot, xanh dương LoRA, cam bước chọn và tổng hợp, đỏ kiểm toán.

B Prompt và định dạng đầu ra

```
# Câu hỏi định vị (C0, C2--C4)
Is there a lung nodule or mass on this chest X-ray? If yes, give the bounding
box(es) in pixel coordinates. Answer in JSON.

# Câu hỏi chỉ phân loại (C1)
Is there a lung nodule or mass on this chest X-ray? Answer in JSON.

# Đáp án đích (C0, C2--C4); C1 chỉ có khoá nodule
{"nodule": "yes", "boxes": [[412, 230, 468, 281]]}   # ca dương, toạ độ trên ảnh
    896×896
{"nodule": "no", "boxes": []}                        # ca âm
```

Parser chấp nhận JSON hợp lệ có khoá `nodule` nhận `yes`/`no`. Box không hợp lệ (toạ độ ngoài ảnh, $x_2 \leq x_1$) bị loại. Câu trả lời không parse được tính là "no" khi tính sensitivity/specificity thô, bị loại khỏi các chỉ số chế độ báo bình thường, và tỷ lệ của chúng được báo riêng.

C Siêu tham số

Bảng 11. Siêu tham số huấn luyện.

Thành phần	Giá trị
LoRA	$r = 16$, $\alpha = 32$, dropout 0,05; attention + MLP của LLM
Bộ mã hoá ảnh	đông cứng
Tối ưu	AdamW, lr 10^{-4}, cosine, warmup 3%
Epoch, batch	3 epoch; batch 1 × tích luỹ gradient 8
Độ chính xác	bf16, gradient checkpointing
Ảnh âm/ảnh dương khi huấn luyện	tối đa 4:1
C3	oversampling 1:1 (`--balance`); $w_+ = 2$ (`--pos-weight 2.0`), áp lên mọi token đáp án ca dương
Phần cứng	GPU compute capability ≥ 8 (L4/A100) cho MedGemma
Sinh văn bản	tối đa 256 token ở C0; 96 token (mặc định) ở C2–C4, 16 token ở C1; nhiệt độ 0 (thêm 2 lần 0,7 ở E2)
B1 DenseNet-121	Adam, lr 10^{-4}, 10 epoch, batch 32, BCE có `pos_weight`
B2 YOLOv8	ảnh 896, 50 epoch, batch 16

D Mã nguồn và tái lập

Mã nguồn nằm trong gói Python `nodulecxr` (thư mục `code/`), viết theo hướng kiểm thử trước, gồm các module: chuẩn bị dữ liệu và hợp nhất box, prompt và parser, huấn luyện LoRA, baseline CNN, chỉ số phát hiện và định vị, thống kê, kiểm toán che vùng, và tổng hợp bảng. Các bước cần GPU chạy trên Colab theo `RUNBOOK.md`. Bảng kết quả trong báo cáo được sinh từ file dự đoán JSONL, không gõ tay.

E Mức kiểm chứng tài liệu

Tổng quan dựa trên 90 bài (`docs/lit-review/lung-cancer-cxr/corpus.md`). Hai bài cốt lõi [2, 3] đã qua bình duyệt và được đọc toàn văn ([3] qua bản preprint medRxiv). Các bài preprint ([25, 27, 28, 36]) chưa qua bình duyệt và được trích dẫn thận trọng.